Análisis y Ejemplos de Uso de MapReduce

Laboratorio Calificado 01 — Dataset MIDIS Diciembre 2024

CC531 — Análisis en Macrodatos

A. Pacheco **C. Malvaceda** **O. Torres**

Abril 2026

FACULTAD DE CIENCIAS

Table of Contents

- Introducción
- Resultados — Consultas 1 a 6
- Resultados — Consultas 7 a 12
- Síntesis y conclusiones

Agenda

1. Introducción y objetivos
2. Dataset MIDIS: Cobertura de Programas Sociales
3. Fundamento: Hadoop y MapReduce
4. Metodología: instalación y ejecución
5. Resultados — 12 consultas MapReduce
6. Síntesis e insights
7. Conclusiones

Integrantes: Andre Pacheco (20222189G), Carlos Malvaceda (20190424F), Oscar Torres (20210153B)

Introducción y objetivos

Motivación

El análisis de grandes volúmenes de datos es clave para la toma de decisiones en el sector público. El MIDIS publica mensualmente la cobertura de sus programas sociales a nivel distrital.

Objetivo del laboratorio

Implementar 12 consultas **MapReduce** sobre el dataset "Cobertura de Programas Sociales adscritos al MIDIS" (diciembre 2024) usando **Apache Hadoop 3.3.6** en modo pseudo-distribuido.

- Programas cubiertos: JUNTOS, PENSIÓN 65, QALI WARMA, CUNAMAS, FONCODES, CONTIGO, PAIS
- Alcance: 1 892 distritos del Perú agrupados por departamento

Dataset MIDIS — Cobertura de Programas Sociales

Atributo	Valor
Institución	MIDIS
Fecha de corte	Diciembre 2024
Formato	CSV (separador ";")
Registros	1 892 distritos
Columnas	18 campos
Fuente	PNDA (datosabiertos.gob.pe)

Campo UBIGEO (6 dígitos)

DD PP DD → Departamento · Provincia · Distrito

Idea clave: extrayendo los 2 primeros dígitos del UBIGEO agrupamos los resultados a nivel departamental.

Fundamento: Hadoop y MapReduce

Componentes de Hadoop

- **HDFS**: almacenamiento distribuido con replicación
- **MapReduce**: paradigma Map → Shuffle → Reduce
- **YARN**: gestor de recursos del clúster
- **Hadoop Common**: utilidades compartidas

Flujo MapReduce

1. *Map*: filtra y emite pares ⟨k,v⟩ intermedios
2. *Shuffle & Sort*: agrupa por clave
3. *Reduce*: agrega y emite resultado final

Entorno utilizado

Apache Hadoop 3.3.6 · Java 11 (Eclipse Temurin) · macOS Apple Silicon M3 · API clásica `org.apache.hadoop.mapred`

Instalación

- Hadoop 3.3.6 en modo pseudo-distribuido (single-node)
- Configuración de `core-site`, `hdfs-site`, `mapred-site`, `yarn-site`
- SSH sin contraseña + formateo de NameNode
- Daemons activos: NameNode, DataNode, SecondaryNameNode, ResourceManager, NodeManager

Dataset

- Ingesta a HDFS: `hadoop fs -put DICIEMBRE_2024.csv /midis/`

Implementación

- 12 módulos Java (`consulta01–consulta12`), cada uno con clases *Mapper*, *Reducer* y *Driver*
- Compilación con `javac` + `jar`; ejecución vía `hadoop jar ….jar SalesCountry.SalesCountryDriver`
- 15 aplicaciones MapReduce ejecutadas y confirmadas con estado **SUCCEEDED** en YARN

Table of Contents

2 Resultados — Consultas 1 a 6

- Introducción
- Resultados — Consultas 1 a 6
- Resultados — Consultas 7 a 12
- Síntesis y conclusiones

C1 — Total hogares JUNTOS por departamento

Tipo: Agregación multi-campo (Tipo 1)

Enunciado: total de hogares afiliados y abonados al programa JUNTOS por departamento.

Mapper: extrae los 2 primeros dígitos del UBIGEO; emite (depto, afiliados + abonados).

Reducer: suma los valores por clave.

Resultado: Cajamarca (06) lidera con **217 275** hogares; Piura (20) con 189 664. Total nacional: **1 427 481 hogares**.
YARN: 12s, SUCCEEDED.

```
(base) danyelliot@Mac ~ % hadoop fs -cat */output_c01/*
2026-04-12 20:08:21,809 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
01      68673
02      75267
03      59987
04      37327
05      63481
06      217275
07      9351
08      86648
09      57175
10      89633
11      14868
12      68686
13      112897
14      47893
15      79436
16      112598
17      5276
18      2425
19      38837
20      189664
21      86853
22      84928
23      8214
24      9757
25      25308
(base) danyelliot@Mac ~ %
```

C2 — Usuarios PENSIÓN 65 y CONTIGO por depto.

Tipo: Agregación multi-campo (Tipo 1)

Campos: UBIGEO, PENSIÓN 65 (col. 11), CONTIGO (col. 14)

Mapper: emite (depto, pensión65 + contigo) por distrito.

Reducer: suma total de beneficiarios combinados por departamento.

Resultado: liderazgo de Cajamarca (106 995), Puno (83 005), Piura (77 472) — regiones con alta población adulta mayor en pobreza.
YARN: 11s.

```
(base) danyelliot@Mac ~ % hadoop fs -cat "/output_c02/*"
2026-04-14 19:21:00,947 WARN util.NativeCodeLoader: Unable to load native-hado
op library for your platform... using builtin-java classes where applicable
01      27108
02      53943
03      37756
04      17060
05      47357
06      106995
07      9837
08      64642
09      33309
10      46979
11      11534
12      44587
13      48867
14      32150
15      83005
16      44299
17      3033
18      4649
19      12157
20      77472
21      79227
22      42186
23      4539
24      9463
25      21803
(base) danyelliot@Mac ~ %
```

C3 — Distritos con CUNAMAS activo

2 Resultados — Consultas 1 a 6

Tipo: Conteo condicional (Tipo 1)

Lógica: si Cuidado Diurno *o* Acompañamiento de Familias > 0, cuenta el distrito como activo.

Mapper: emite (depto, 1) si cualquiera de los dos campos CUNAMAS es positivo.

Reducer: cuenta distritos activos por depto.

Resultado: Cajamarca lidera con **124** distritos activos; Junín y Loreto con 112. Pasco solo tiene 3. CUNAMAS está presente en los 25 departamentos.

```
(base) danyelliot@Mac Downloads % hadoop fs -cat "/output_c03/*"

2026-04-14 20:16:51,211 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
01	63
02	122
03	82
04	55
05	112
06	124
07	3
08	111
09	84
10	83
11	35
12	112
13	75
14	34
15	47
16	48
17	11
18	11
19	28
20	56
21	102
22	58
23	19
24	13
25	18
(base) danyelliot@Mac Downloads %
```

C4 — Niños e IIEE de QALI WARMA

2 Resultados — Consultas 1 a 6

Tipo: Doble agregación con clave compuesta (Tipo 1)

Trick: el mapper emite *dos* pares por registro: `(depto_ninos, N)` y `(depto_iiee, M)` → obtiene ambos totales en una sola pasada.

Resultado:

- Puno: **757 118 niños** atendidos
- Lima: 270 169 niños
- Puno lidera también en IIEE (4 676)
- Pasco y Madre de Dios: menor cobertura (∼348 IIEE)

```
(base) danyelliot@Mac classes % hadoop fs -cat */output_c04/*
2026-04-14 20:35:46.453 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
01_iiee 2056
01_ninos        114734
02_iiee 3640
02_ninos        169709
03_iiee 2009
03_ninos        81629
04_iiee 1609
04_ninos        138873
05_iiee 2785
05_ninos        115362
06_iiee 7757
06_ninos        258668
07_iiee 348
07_ninos        99464
08_iiee 4185
08_ninos        204560
09_iiee 2551
09_ninos        75044
10_iiee 3487
10_ninos        148363
11_iiee 905
11_ninos        121438
12_iiee 3638
12_ninos        178392
13_iiee 3093
13_ninos        278169
14_iiee 1523
14_ninos        138898
15_iiee 7997
15_ninos        757118
16_iiee 4381
16_ninos        268737
17_iiee 793
17_ninos        41571
18_iiee 367
18_ninos        21597
19_iiee 1377
19_ninos        55629
20_iiee 4281
20_ninos        333609
21_iiee 4676
21_ninos        173858
22_iiee 2496
22_ninos        182848
23_iiee 488
23_ninos        38897
24_iiee 366
24_ninos        48170
25_iiee 1781
25_ninos        138182
(base) danyelliot@Mac classes %
```

C5 — Mayor y menor cobertura JUNTOS

2 Resultados — Consultas 1 a 6

Tipo: Valor máximo y mínimo agrupado (Tipo 5)

Reducer: mantiene dos variables `mayor` (MIN_VALUE) y `menor` (MAX_VALUE), recorre los valores del iterador y emite ambos registros.

Resultado:

- Piura (20): distrito más grande con **8 539** hogares
- Pasco (16): 7 193 hogares
- Valores 0 indican distritos sin cobertura

```
(base) danyelliot@Mac classes % hadoop fs -cat "/output_c05/*"
2026-04-14 20:44:06,635 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
01_mayor        3675
01_menor        4
02_mayor        1428
02_menor        2
03_mayor        1727
03_menor        21
04_mayor        1139
04_menor        1
05_mayor        1836
05_menor        8
06_mayor        6184
06_menor        15
07_mayor        2744
07_menor        0
08_mayor        1899
08_menor        18
09_mayor        2680
09_menor        12
10_mayor        2060
10_menor        39
11_mayor        469
11_menor        3
12_mayor        3731
12_menor        1
13_mayor        3660
13_menor        18
14_mayor        3853
14_menor        20
15_mayor        4388
15_menor        0
16_mayor        7193
16_menor        54
17_mayor        1432
17_menor        37
18_mayor        530
18_menor        2
19_mayor        1742
19_menor        11
20_mayor        8539
20_menor        13
21_mayor        2090
21_menor        19
22_mayor        2081
22_menor        17
23_mayor        1574
23_menor        0
24_mayor        1537
24_menor        63
25_mayor        2340
25_menor        44
(base) danyelliot@Mac classes %
```

C6 — Estadísticas de PENSIÓN 65

2 Resultados — Consultas 1 a 6

Tipo: Promedio, mediana, desviación estándar (Tipo 2)

Reducer: acumula todos los valores en una lista, calcula $\bar{x}$, ordena para mediana, aplica fórmula de varianza poblacional.

Depto	Prom.	Med.	σ
Ucayali (25)	1004	401	1376
Piura (20)	996	765	932
Pasco (07)	1022	310	1209
Apurímac (04)	141	103	147

Alta σ en Ucayali/Pasco $\Rightarrow$ gran disparidad entre distritos.

```
2026-04-14 20:51:36.531 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
01      promedio=246.20 mediana=117.00 desviacion=360.92 n=84
02      promedio=292.41 mediana=187.00 desviacion=313.55 n=166
03      promedio=390.75 mediana=255.00 desviacion=351.87 n=80
04      promedio=141.32 mediana=103.00 desviacion=147.37 n=109
05      promedio=330.70 mediana=229.00 desviacion=330.30 n=124
06      promedio=716.73 mediana=469.00 desviacion=782.99 n=127
07      promedio=1022.29 mediana=310.00 desviacion=1209.44 n=7
08      promedio=489.60 mediana=394.00 desviacion=386.08 n=116
09      promedio=266.46 mediana=166.00 desviacion=269.01 n=102
10      promedio=658.57 mediana=350.00 desviacion=335.90 n=84
11      promedio=218.74 mediana=150.00 desviacion=143.89 n=48
12      promedio=321.49 mediana=168.00 desviacion=401.99 n=124
13      promedio=477.19 mediana=383.00 desviacion=418.21 n=84
14      promedio=799.37 mediana=222.50 desviacion=548.66 n=38
15      promedio=300.33 mediana=117.00 desviacion=492.23 n=171
16      promedio=752.89 mediana=309.00 desviacion=958.39 n=53
17      promedio=212.27 mediana=180.00 desviacion=294.30 n=11
18      promedio=192.17 mediana=130.00 desviacion=144.64 n=21
19      promedio=326.00 mediana=252.00 desviacion=242.42 n=29
20      promedio=996.49 mediana=765.00 desviacion=932.22 n=66
21      promedio=671.13 mediana=421.00 desviacion=695.58 n=110
22      promedio=441.24 mediana=288.00 desviacion=396.24 n=78
23      promedio=142.64 mediana=85.00 desviacion=154.72 n=28
24      promedio=626.77 mediana=387.00 desviacion=584.41 n=13
25      promedio=1004.68 mediana=401.00 desviacion=1376.73 n=19
(base) danyelilot@Mac classes %
```

Table of Contents

3 Resultados — Consultas 7 a 12

- Introducción
- Resultados — Consultas 1 a 6
- Resultados — Consultas 7 a 12
- Síntesis y conclusiones

C7 — Búsqueda de subtexto en UBIGEO

3 Resultados — Consultas 7 a 12

Tipo: Búsqueda por subtexto (Tipo 3)

Enunciado: obtener los registros completos de Amazonas (código “01”).

Mapper: si `ubigeo.startsWith("01")`, emite (ubigeo, línea_completa).

Reducer: pasa los registros tal cual al output.

Resultado: 84 registros correspondientes a los 84 distritos de Amazonas. Ej.: distrito 010101 → 96 en CUNAMAS, 494 hogares JUNTOS, 637 usuarios PENSIÓN 65.

```
2026-04-14 21:01:24,112 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
010101  2024;1291;010101;96;165;494;479;;;;;;637;9234;34;250;;;
010102  2024;1291;010102;;14;15;;;;;;38;10;4;4;;;
010103  2024;1291;010103;0;19;106;100;1544;;;;400;0;68;262;15;14;;;
010104  2024;1291;010104;3;6;16;7;36;;;;;;;58;9;4;16;;;
010105  2024;1291;010105;0;5;8;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010106  2024;1291;010106;0;64;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010107  2024;1291;010107;0;2;29;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010108  2024;1291;010108;0;0;31;31;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010109  2024;1291;010109;0;19;;658;648;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010110  2024;1291;010110;0;137;229;222;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010111  2024;1291;010111;0;36;19;35;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010112  2024;1291;010112;;40;59;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010113  2024;1291;010113;0;3;40;46;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010114  2024;1291;010114;0;69;163;163;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010115  2024;1291;010115;;38;37;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010116  2024;1291;010116;0;2;29;29;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010117  2024;1291;010117;0;9;79;79;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010118  2024;1291;010118;;0;6;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010119  2024;1291;010119;0;17;45;46;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
010120  2024;1291;010120;0;0;111;110;164R;;;;;;;;;;;;;;;;;;;;;;;;;;;;;;
(base) danyelizOMac classes %
```

C8 — Búsqueda por intervalo de fechas

3 Resultados — Consultas 7 a 12

Tipo: Filtro temporal (Tipo 4)

Rango: 20241201 $\leq$ FECHA_CORTE $\leq$ 20241231

Mapper: usa comparación lexicográfica de strings en formato `yyyyMMdd` — válida y eficiente.

Resultado: 1 892 registros devueltos (todo el dataset es de diciembre 2024). Demuestra el mecanismo de filtrado aplicable a datasets multi-período.

```
2026-04-14 21:05:19,669 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
20241231        20241231;100204;0;104;402;476;;;;;;;385;843;20;69;;;
20241231        20241231;100203;0;60;172;169;56;;1;0;400;211;309;20;21;1;429;335
20241231        20241231;100202;0;115;394;387;;;;;;267;481;21;42;1;919;373
20241231        20241231;100201;104;208;1317;1203;;;;;;1007;465a;73;193;;;
20241231        20241231;100113;0;488;963;931;;;;0;400;421;2207;54;147;1;335;236
cat: Unable to write to output stream.
(base) danyelliot@Mac classes %
```

C9 — Ratio abonados/afiliados JUNTOS (2 MR encadenados)

Tipo: 2 MapReduce encadenados con decimales (Tipo 6)

Job 1: acumula totales (afiliados, abonados) por depto.

Job 2: lee el output y calcula ratio $= \frac{\text{abonados}}{\text{afiliados}} \times 100$.

Hallazgos:

- Cajamarca (06): **98.51%** — ratio más alto
- Ancash: 98.28%
- Ucayali: 89.03% — ratio más bajo (posibles dificultades logísticas de pago)

Mayoría de departamentos $> 95\%$.

```
2026-04-14 21:25:00,650 WARN util.NativeCodeLoader: Unable
01      afiliados=34830 abonados=33843 ratio=97.17%
02      afiliados=37959 abonados=37308 ratio=98.28%
03      afiliados=30270 abonados=29717 ratio=98.17%
04      afiliados=8976 abonados=8351 ratio=93.04%
05      afiliados=32155 abonados=31246 ratio=97.17%
06      afiliados=109455 abonados=107820 ratio=98.51%
07      afiliados=4872 abonados=4379 ratio=89.88%
08      afiliados=43749 abonados=42899 ratio=98.06%
09      afiliados=28924 abonados=28251 ratio=97.67%
10      afiliados=45589 abonados=44044 ratio=96.61%
11      afiliados=7772 abonados=7093 ratio=91.26%
12      afiliados=31048 abonados=29638 ratio=95.46%
13      afiliados=57127 abonados=54970 ratio=96.22%
14      afiliados=24031 abonados=23062 ratio=95.97%
15      afiliados=38236 abonados=35399 ratio=92.58%
16      afiliados=58740 abonados=53858 ratio=91.69%
17      afiliados=2784 abonados=2492 ratio=89.51%
18      afiliados=1236 abonados=1189 ratio=96.20%
19      afiliados=9309 abonados=8728 ratio=93.76%
20      afiliados=96505 abonados=93159 ratio=96.53%
21      afiliados=43312 abonados=42540 ratio=98.22%
22      afiliados=43201 abonados=41727 ratio=96.59%
23      afiliados=4221 abonados=4003 ratio=94.84%
24      afiliados=5073 abonados=4684 ratio=92.33%
25      afiliados=13388 abonados=11920 ratio=89.03%
(base) danyelliot@Mac classes %
```

C10 — Ratio niños/IIEE de QALI WARMA

3 Resultados — Consultas 7 a 12

Tipo: 2 MapReduce encadenados (Tipo 6)

Objetivo: promedio de niños atendidos por institución educativa.

Depto	Niños/IIEE	Niños
Pasco (07)	**285.82**	99 464
Puno (15)	189.42	757 118
Ica (11)	134.19	121 438
Cajamarca (06)	35.16	258 668

Pasco concentra ∼286 niños por IIEE ⇒ potencial **sobrecarga**. Cajamarca mejor distribución (más escuelas por niño).

```
2026-04-14 22:13:36,535 WARN util.NativeCodeLoader: Unable
01      ninos=114734 iiee=2556 ratio=44.89 ninos/IIEE
02      ninos=169709 iiee=3660 ratio=46.37 ninos/IIEE
03      ninos=81629 iiee=2009 ratio=40.63 ninos/IIEE
04      ninos=130873 iiee=1609 ratio=81.34 ninos/IIEE
05      ninos=115362 iiee=2785 ratio=41.42 ninos/IIEE
06      ninos=258668 iiee=7357 ratio=35.16 ninos/IIEE
07      ninos=99464 iiee=348 ratio=285.82 ninos/IIEE
08      ninos=204560 iiee=4105 ratio=49.83 ninos/IIEE
09      ninos=75044 iiee=2551 ratio=29.42 ninos/IIEE
10      ninos=148363 iiee=3407 ratio=43.55 ninos/IIEE
11      ninos=121438 iiee=905 ratio=134.19 ninos/IIEE
12      ninos=178392 iiee=3638 ratio=49.04 ninos/IIEE
13      ninos=270169 iiee=3593 ratio=75.19 ninos/IIEE
14      ninos=138090 iiee=1623 ratio=85.08 ninos/IIEE
15      ninos=757118 iiee=3997 ratio=189.42 ninos/IIEE
16      ninos=268737 iiee=4381 ratio=61.34 ninos/IIEE
17      ninos=41571 iiee=393 ratio=105.78 ninos/IIEE
18      ninos=21597 iiee=347 ratio=62.24 ninos/IIEE
19      ninos=55629 iiee=1377 ratio=40.40 ninos/IIEE
20      ninos=333609 iiee=4281 ratio=77.93 ninos/IIEE
21      ninos=173050 iiee=4676 ratio=37.01 ninos/IIEE
22      ninos=182840 iiee=2696 ratio=67.82 ninos/IIEE
23      ninos=38097 iiee=480 ratio=79.37 ninos/IIEE
24      ninos=40170 iiee=366 ratio=109.75 ninos/IIEE
25      ninos=138182 iiee=1701 ratio=81.24 ninos/IIEE
(base) danyelliot@Mac classes %
```

C11 — Clasificación por nivel de cobertura PENSIÓN 65

3 Resultados — Consultas 7 a 12

Tipo: Modelo de clasificación por reglas (Tipo 7)

Niveles: SIN_COBERTURA (0), BAJA (1-50), MEDIA (51-200), ALTA (201-500), MUY_ALTA (>500).

Depto	BAJA	MED	ALT	MUY
06 Cajamarca	0	15	55	**57**
15 Puno	31	86	21	33
20 Piura	1	12	11	41
04 Apurímac	19	73	15	2

Cajamarca concentra cobertura MUY_ALTA; Puno dispersa; Apurímac mayor en MEDIA pero sin intensidad.

```
2026-04-14 22:17:21,169 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
01_ALTA distritos=20
01_BAJA distritos=17
01_MEDIA        distritos=37
01_MUY_ALTA     distritos=18
02_ALTA distritos=62
02_BAJA distritos=14
02_MEDIA        distritos=73
02_MUY_ALTA     distritos=35
03_ALTA distritos=28
03_BAJA distritos=2
03_MEDIA        distritos=31
03_MUY_ALTA     distritos=24
04_ALTA distritos=15
04_BAJA distritos=19
04_MEDIA        distritos=73
04_MUY_ALTA     distritos=2
05_ALTA distritos=63
05_BAJA distritos=7
05_MEDIA        distritos=41
05_MUY_ALTA     distritos=23
06_ALTA distritos=55
06_MUY_ALTA     distritos=15
06_MUY_ALTA     distritos=57
07_ALTA distritos=2
07_BAJA distritos=1
07_MEDIA        distritos=1
07_MUY_ALTA     distritos=3
08_ALTA distritos=61
08_BAJA distritos=2
08_MEDIA        distritos=18
08_MUY_ALTA     distritos=45
09_ALTA distritos=34
09_BAJA distritos=5
09_MEDIA        distritos=68
09_MUY_ALTA     distritos=15
10_ALTA distritos=37
10_BAJA distritos=1
10_MEDIA        distritos=19
10_MUY_ALTA     distritos=27
11_ALTA distritos=13
11_BAJA distritos=3
11_MEDIA        distritos=35
11_MUY_ALTA     distritos=2
12_ALTA distritos=32
12_BAJA distritos=18
12_MEDIA        distritos=40
12_MUY_ALTA     distritos=22
13_ALTA distritos=34
13_BAJA distritos=1
13_MEDIA        distritos=19
13_MUY_ALTA     distritos=30
```

C12 — Regresión lineal PENSIÓN 65 por depto.

Tipo: Modelo de regresión lineal (Tipo 8)

X: últimos 4 dígitos del UBIGEO (índice del distrito)

Y: usuarios PENSIÓN 65

Reducer aplica mínimos cuadrados:

$$\hat{b}_1 = \frac{n\sum XY - \sum X \sum Y}{n\sum X^2 - (\sum X)^2}$$

Depto	Modelo	Tend.
14 Lambayeque	$y = 2.26x + 286$	$+$
07 Pasco	$y = -45.25x + 5728$	$--$
20 Piura	$y = -2.09x + 1866$	$-$

Pendiente negativa predominante $\Rightarrow$ primeros distritos (capitales) concentran más usuarios.

```
(base) danyelliot@Mac classes % hadoop fs -cat "/output_c12/*"
2026-04-14 22:21:22,504 WARN util.NativeCodeLoader: Unable to
01      y = 0.3726*x + 102.3941  (n=84 distritos)
02      y = -0.0184*x + 312.3560  (n=166 distritos)
03      y = -0.5623*x + 618.5731  (n=86 distritos)
04      y = -0.0672*x + 167.7032  (n=109 distritos)
05      y = -0.4893*x + 629.6189  (n=124 distritos)
06      y = -0.3636*x + 961.2789  (n=127 distritos)
07      y = -45.2500*x + 5728.2857  (n=7 distritos)
08      y = -0.0255*x + 508.2834  (n=116 distritos)
09      y = -0.1521*x + 352.6718  (n=102 distritos)
10      y = -0.2918*x + 611.0639  (n=84 distritos)
11      y = -0.0858*x + 233.3705  (n=43 distritos)
12      y = -0.0944*x + 361.4445  (n=124 distritos)
13      y = 0.1138*x + 427.6804  (n=84 distritos)
14      y = 2.2613*x + 286.3352  (n=38 distritos)
15      y = -0.9477*x + 921.2959  (n=171 distritos)
16      y = -1.9664*x + 1573.8776  (n=53 distritos)
17      y = -1.7213*x + 544.9626  (n=11 distritos)
18      y = -0.9326*x + 365.3829  (n=21 distritos)
19      y = 0.9873*x + 139.0166  (n=29 distritos)
20      y = -2.0907*x + 1866.1080  (n=65 distritos)
21      y = -0.2652*x + 834.0776  (n=110 distritos)
22      y = -0.1144*x + 530.7187  (n=78 distritos)
23      y = -0.5172*x + 263.2353  (n=28 distritos)
24      y = -1.5100*x + 809.8359  (n=13 distritos)
25      y = -7.9333*x + 2702.8307  (n=19 distritos)
(base) danyelliot@Mac classes %
```

Table of Contents

4 Síntesis y conclusiones

- Introducción
- Resultados — Consultas 1 a 6
- Resultados — Consultas 7 a 12
- Síntesis y conclusiones

Síntesis: patrones observados

Departamentos protagonistas

- **Cajamarca (06)**: líder en JUNTOS, CUNAMAS y clasificación MUY_ALTA de PENSIÓN 65 — refleja mayor incidencia de pobreza
- **Puno (15)**: líder absoluto en QALI WARMA (757K niños)
- **Piura (20)**: segundo en JUNTOS, alto en PENSIÓN 65

Alertas detectadas

- **Pasco (07)**: ratio niños/IIEE de 285.82 $\Rightarrow$ sobrecarga de aulas
- **Ucayali (25)**: ratio pago JUNTOS 89% — dificultades logísticas
- Alta σ en PENSIÓN 65 en regiones amazónicas $\Rightarrow$ inequidad distrital

Conclusiones

4 Síntesis y conclusiones

- Se instaló y configuró **Apache Hadoop 3.3.6** en modo pseudo-distribuido sobre macOS Apple Silicon — requirió Java 11 (Java 25 rompe la API de seguridad de Hadoop).
- Se implementaron exitosamente **las 12 consultas** que cubren los 8 tipos del laboratorio: agregaciones, estadísticas, búsquedas, MR encadenados, clasificación y regresión.
- El análisis revela que **Cajamarca y Piura** concentran la mayor cantidad de beneficiarios de JUNTOS, coherente con los índices de pobreza regional del Perú.
- JUNTOS opera con alta **eficiencia de pago** ($>95\%$) en la mayoría de departamentos.
- La regresión lineal sugiere que en casi todos los departamentos los **distritos capitales** concentran más beneficiarios de PENSIÓN 65 $\Rightarrow$ sesgo urbano.

Referencias

1. MIDIS (2024). *Cobertura de los Programas Sociales adscritos al MIDIS*, diciembre 2024. Plataforma Nacional de Datos Abiertos del Perú.
2. Dean, J. & Ghemawat, S. (2004). *MapReduce: Simplified Data Processing on Large Clusters.* Google Inc., OSDI'04.
3. White, T. (2015). *Hadoop: The Definitive Guide.* O'Reilly Media.
4. Apache Hadoop Project (2023). *Hadoop 3.3.6 Documentation.*
5. Francke, P. & Acosta, G. (2021). *Impacto de Qali Warma sobre anemia y desnutrición crónica infantil.* Apuntes 48(88).
6. Pecho, J. et al. (2024). *Social Programs and Socioeconomic Variables: Impact on Peruvian Regional Poverty 2013–2022.* Economies 12(8).

Repositorio GitHub: danyelliot/MacrodatosHadoop

Análisis y Ejemplos de Uso de MapReduce

Gracias por escucharme!